

OOLONG-Pairs · полный разбор

ШАГ 0. Сначала – что такое TREC. Это бабушка NLP-датасетов

TREC = Text Retrieval Conference · с 1992 года · организует NIST (амер. институт стандартов)

Question Classification dataset (2002): ~5 500 коротких вопросов на английском, каждый размечен ОДНОЙ из 6 КАТЕГОРИЙ:

HUM (про человека)	LOC (про место)	NUM (про число)
ABBR (про аббревиатуру)	ENTY (про объект)	DESC (про описание)

MIT не выдумывали ничего нового – взяли проверенную 20 лет базу и придумали для неё новый тип задач.

ШАГ 1. MIT берут ~500 записей из TREC. Каждая = вопрос + категория

#1 «Какая столица Японии?»
→ LOC

#2 «Кто написал Войну и Мир?»
→ HUM

#3 «Что означает NASA?»
→ ABBR

#4 «Сколько весит слон?»
→ NUM

#5 «Кто изобрёл телефон?»
→ HUM

#6 «Где находится Эверест?»
→ LOC

#7 «Кто написал Гарри Поттера?»
→ HUM

#8 «Что значит CPU?»
→ ABBR


... ещё 492 таких записи ...

ВСЕГО: ~500 записей · 32 000 токенов

ШАГ 2. Что такое «пара»? Любые ДВЕ разные уникальные записи.

Все пары на 7 записях – 21 связь:

(#1, #2), (#1, #3), (#1, #4), (#1, #5), (#1, #6), (#1, #7) – 6 пар
(#2, #3), (#2, #4), (#2, #5), (#2, #6), (#2, #7) – 5 пар
(#3, #4), (#3, #5), (#3, #6), (#3, #7) – 4 пары
(#4, #5), (#4, #6), (#4, #7) – 3 пары
(#5, #6), (#5, #7) – 2 пары
(#6, #7) – 1 пара



Формула числа пар:

$$C(n, 2) = n \times (n - 1) / 2$$

Примеры:

$n = 7 \rightarrow 7 \times 6 / 2 = 21$ пара
 $n = 50 \rightarrow 50 \times 49 / 2 = 1\,225$ пар
 $n = 500 \rightarrow 500 \times 499 / 2 = 124\,750$ пар + наш случай
 $n = 1000 \rightarrow 1000 \times 999 / 2 = 499\,500$ пар

ШАГ 3. В тесте 20 вопросов – каждый требует агрегации по парам. Вот примеры:

Вопрос #1: «Сколько пар, где ОБЕ из категории HUM?»
Вопрос #2: «Сколько пар, где ОБЕ из категории LOC?»
Вопрос #3: «Сколько пар, где первая HUM, а вторая LOC?»
Вопрос #4: «Сколько пар, где категории РАЗНЫЕ?»
Вопрос #5: «Сколько пар, где первая короче второй по словам?»
... ещё 15 таких вопросов ...

Каждый вопрос – отдельный запуск. Модель получает все 500 записей + один вопрос + возвращает ЧИСЛО.

ШАГ 4. Возьмём вопрос #1 и пройдем по парам – модель должна сделать ~125 000 проверок

Вопрос: «Сколько пар, где ОБЕ HUM?»

(#1 «Столица Японии» LOC + #2 «Кто Толстой» HUM) → LOC × HUM → × не подходит

(#2 «Кто Толстой» HUM + #5 «Кто изобрёл телефон» HUM) → HUM × HUM → ✓ подходит

(#3 «Что NASA» ABBR + #4 «Сколько весит слон» NUM) → ABBR × NUM → × не подходит

(#2 «Кто Толстой» HUM + #7 «Кто Гарри Поттер» HUM) → HUM × HUM → ✓ подходит

... и так ещё 124 996 пар ...

Считаем сколько ✓ всего получилось → это ответ модели

ШАГ 5. Сравниваем ответ с эталоном – это и есть F1-score

ЭТАЛОН (правильный ответ)

Если в датасете 50 записей HUM –
это $50 \times 49 / 2 = 1\,225$ пар

GPT-5 сырой ответил:

0 пар
F1 ≈ 0.1% ❌

RLM (та же GPT-5):

~720 пар
F1 ≈ 58% ✅